

République Algérienne Démocratique et Populaire  
Ministère de l'Enseignement Supérieur et de la Recherche Scientifique



Université des Sciences et de la Technologie Houari Boumédiène

Faculté d'Informatique  
Département Informatique

Master Systèmes Informatiques intelligents

Module : Représentation de connaissances et raisonnement 2

---

## Rapport des TP's RCR

---

Réalisé par :

FERKOUS Sarah, 191931043867  
KHEMISSI Maroua, 191935007943

Année universitaire : 2023 / 2024

# Table des matières

<b>1</b>	<b>TP1 : Logique des fonctions de croyances</b>	<b>4</b>
1.1	Introduction : . . . . .	4
1.2	L'outil choisie . . . . .	4
1.3	Exemple D'application . . . . .	4
1.3.1	Modélisation des connaissances . . . . .	4
1.3.2	Modélisation avec pyds . . . . .	5
1.4	Conclusion : . . . . .	5
<b>2</b>	<b>TP2 : Contrôleurs flous</b>	<b>7</b>
2.1	Introduction . . . . .	7
2.2	Problème . . . . .	8
2.2.1	Enoncé . . . . .	8
2.3	Résolution . . . . .	9
2.3.1	Initialisation des E/S . . . . .	9
2.3.2	Fuzification . . . . .	10
2.3.3	Les Regles . . . . .	11
2.3.4	Fonctionnement . . . . .	12
2.3.5	Defuzzification . . . . .	13
2.4	Conclusion . . . . .	14
<b>3</b>	<b>TP3 :Réseaux causaux Bayésiens</b>	<b>15</b>
3.1	Introduction : . . . . .	15
3.2	Outil choisie : . . . . .	15
3.3	ÉTAPE 1 : Installation de PGMPY . . . . .	15
3.4	ÉTAPE2 : Poly-Arbre . . . . .	16
3.4.1	Modelisation avec PGMPY . . . . .	18
3.5	ÉTAPE3 : Multi-Arbre . . . . .	21
3.5.1	Modelisation avec PGMPY . . . . .	22
3.6	ÉTAPE4 : Générez un graphe à connexions multiples avec un Grand Nombre de Variables et de Parents . . . . .	24
3.7	Conclusion . . . . .	26
<b>4</b>	<b>TP4 : Logique possibiliste qualitative</b>	<b>27</b>
4.1	Introduction . . . . .	27
4.2	La création de la base de connaissances pondérée . . . . .	28
4.3	L'implémentation de l'algorithme en utilisant un prouver SAT . . . . .	29
4.4	L'algorithme calcule la variable d'intérêt $\Pi$ , qui correspond à $val(\phi, \Sigma)$ . . . . .	30
4.5	Conclusion . . . . .	33
<b>5</b>	<b>TP 5 : Théorie des possibilités : Inférence logique et propagation graphique</b>	<b>34</b>
5.1	Introduction . . . . .	34
5.2	Utilisation de Cygwin . . . . .	34
5.2.1	ÉTAPE 1 : Utilisation d'un algorithme de propagation pour les réseaux possibilistes basés sur le produit . . . . .	34

5.2.2	ÉTAPE 2 : Exécution des fichiers . . . . .	35
5.2.3	Evaluation . . . . .	35

# Introduction Generale

La représentation des connaissances consiste à organiser et structurer l'information de manière à faciliter sa compréhension et son utilisation. Elle peut prendre la forme de modèles, schémas ou graphes, facilitant la manipulation et l'analyse des données. Au cours de cette série de travaux pratiques, nous explorerons les méthodes permettant d'accomplir cela, tout en examinant les diverses logiques et les types de raisonneurs qui effectuent des déductions dans ce contexte.

# TP1 : Logique des fonctions de croyances

## 1.1 Introduction :

La théorie de Dempster-Shafer est une théorie mathématique basée sur la notion des preuves en utilisant les fonctions de croyance et le raisonnement plausible. Le but de cette théorie est de permettre de combiner des preuves distinctes afin de raisonner dans une situation incertaine. Cette théorie a été développée par Arthur P.Dempster et Glenn Shafer.

## 1.2 L'outil choisie

La bibliothèque Python utilisée est appelée "pyds" (pyds.py) et elle est utilisée pour effectuer des opérations sur les fonctions de masse de croyance (Belief Mass Functions - BMF) .

## 1.3 Exemple D'application

On a choisi ce exercice pour l'exploitation de cette bibliotheque : Trois experts tentent d'évaluer les causes du changement climatique dans une région donnée.

Le premier expert suggère que le changement climatique est attribuable à 30 aux activités humaines, à 40 aux variations naturelles, et à 30 à des facteurs inconnus.

Le deuxième expert affirme que le changement climatique est principalement dû à des facteurs humains à hauteur de 50, mais il pourrait également être causé par des variations naturelles à 20.

Le dernier expert déclare que le changement climatique est soit résultat d'activités humaines (comme l'industrialisation) à hauteur de 60, soit il est lié à des facteurs inconnue a 40.

### 1.3.1 Modélisation des connaissances

L'ensemble  $\Omega$  est défini comme  $\Omega = \{A, B\}$ . tel que :

A : activités humaines

B : variations naturelles

Le premier expert (E1) croit en :

$$m(A) = 0.3 \quad m(B) = 0.4 \quad m(\Omega) = 0.3$$

Le deuxième expert (E2) croit en :

$$m(A) = 0.5 \quad m(B) = 0.2$$

Le dernier expert (E3) croit en :

$$m(A) = 0.6 \quad m(\Omega) = 0.4$$

### 1.3.2 Modélisation avec pyds

```
from pyds import MassFunction

# Expert 1
print("Expert 1")
m1 = MassFunction({'A': 0.3, 'B': 0.4, 'C': 0.3})
print("m_1 =", m1)

# Expert 2
print("\nExpert 2")
m2 = MassFunction({'A': 0.5, 'B': 0.2})
print("m_2 =", m2)

# Expert 3
print("\nExpert 3")
m3 = MassFunction({'A': 0.6, 'C': 0.4})
print("m_3 =", m3)
```

Expert 1  
m\_1 = {{'B':0.4; {'A':0.3; {'C':0.3}}

Expert 2  
m\_2 = {{'A':0.5; {'B':0.2}}

Expert 3  
m\_3 = {{'A':0.6; {'C':0.4}}

FIGURE 1.1 – Modelisation avec pyds

## 1.4 Conclusion :

Dans nos résultats, on peut voir la croyance maximale associée à chaque combinaison. Regardons chaque cas :

Combinaison de m1 et m2 :

'A' : 0.6521739130434782 'B' : 0.3478260869565218

La proposition avec la plus grande croyance est 'A' (0.6521739130434782).

Combinaison de m2 et m3 :

'A' : 1.0 La proposition avec la plus grande croyance est 'A' (1.0).

Combinaison de m1 et m3 :

'A' : 0.6 'C' : 0.4 La proposition avec la plus grande croyance est 'A' (0.6).

Combinaison de m1, m2 et m3 :

```
#affichage de croyance et plausibilité pour chaque expert
print("Croyance et possibilité pour l'expert 1")
print("bel_1 = ", m1.bel())
print("pl_1 = ", m1.pl())

print("Croyance et possibilité pour l'expert 2")
print("bel_2 = ", m2.bel())
print("pl_2 = ", m2.pl())

print("Croyance et possibilité pour l'expert 3")
print("bel_3 = ", m3.bel())
print("pl_3 = ", m3.pl())

Croyance et possibilité pour l'expert 1
bel_1 = {frozenset(): 0.0, frozenset({'B'}): 0.4, frozenset({'A'}): 0.3, frozenset({'C'}): 0.3, frozenset({'B', 'A'}): 0.7,
pl_1 = {frozenset(): 0.0, frozenset({'B'}): 0.4, frozenset({'A'}): 0.3, frozenset({'C'}): 0.3, frozenset({'B', 'A'}): 0.7,
Croyance et possibilité pour l'expert 2
bel_2 = {frozenset(): 0.0, frozenset({'B'}): 0.2, frozenset({'A'}): 0.5, frozenset({'B', 'A'}): 0.7}
pl_2 = {frozenset(): 0.0, frozenset({'B'}): 0.2, frozenset({'A'}): 0.5, frozenset({'B', 'A'}): 0.7}
Croyance et possibilité pour l'expert 3
bel_3 = {frozenset(): 0.0, frozenset({'C'}): 0.4, frozenset({'A'}): 0.6, frozenset({'C', 'A'}): 1.0}
pl_3 = {frozenset(): 0.0, frozenset({'C'}): 0.4, frozenset({'A'}): 0.6, frozenset({'C', 'A'}): 1.0}
```

FIGURE 1.2 – Croyance et plausibilité pour chaque expert

```
#combinaisons des masses par fusion de Dempster-Shafer
print("Dempster-Shafer Combinaison rule")
print("Dempster-Shafer Combinaison rule for m_1 and m_2 = ", m1 & m2)
print("Dempster-Shafer Combinaison rule for m_2 and m_3 = ", m2 & m3)
print("Dempster-Shafer Combinaison rule for m_1 and m_3 = ", m1 & m3)

print("Dempster-Shafer Combinaison rule for m_1, m_2 and m_3 = ", m1.combine_conjunctive(m2, m3))
print("Dempster-Shafer Combinaison rule for m_2, m_1 and m_3 = ", m2.combine_conjunctive(m1, m3))
print("Dempster-Shafer Combinaison rule for m_3, m_1 and m_2 = ", m3.combine_conjunctive(m1, m2))

Dempster-Shafer Combinaison rule
Dempster-Shafer Combinaison rule for m_1 and m_2 = {'A':0.6521739130434782; 'B':0.3478260869565218}
Dempster-Shafer Combinaison rule for m_2 and m_3 = {'A':1.0}
Dempster-Shafer Combinaison rule for m_1 and m_3 = {'A':0.6; 'C':0.4}
Dempster-Shafer Combinaison rule for m_1, m_2 and m_3 = {'A':0.6521739130434782; 'B':0.3478260869565218}
Dempster-Shafer Combinaison rule for m_2, m_1 and m_3 = {'A':0.6521739130434782; 'B':0.3478260869565218}
Dempster-Shafer Combinaison rule for m_3, m_1 and m_2 = {'A':0.6; 'C':0.4}
```

FIGURE 1.3 – Combinaisons des masses par fusion de Dempster-Shafer

'A' : 0.6521739130434782 'B' : 0.3478260869565218

La proposition avec la plus grande croyance est 'A' (0.6521739130434782).

Combinaison de m2, m1 et m3 :

'A' : 0.6521739130434782 'B' : 0.3478260869565218

La proposition avec la plus grande croyance est 'A' (0.6521739130434782).

Combinaison de m3, m1 et m2 :

'A' : 0.6 'C' : 0.4

La proposition avec la plus grande croyance est 'A' (0.6).

on peut deduire que A ( activités humaines) est le raison le plus forte de changement de climate.

# TP2 : Contrôleurs flous

## 2.1 Introduction

La vie courante est parsemée de concepts qui ne peuvent pas être décrits par des notions mathématiques simples. Chacun de nous manipule ainsi des notions qui sont soit imprécises (assez tôt, important, environ, ...) soit incertaines (il est possible que ...) : "Je cherche un appartement de taille moyenne, pas trop cher et proche du centre ville" ou "Il est possible que le ciel se couvre vers midi". Pour répondre à ces besoins on utilise un contrôleur flou.

Un "contrôleur flou" fait référence à un dispositif ou à un système qui utilise la logique floue pour prendre des décisions ou effectuer des contrôles.

Dans un contrôleur flou, les règles sont exprimées sous forme de propositions linguistiques. Ces propositions sont évaluées en utilisant des ensembles flous et des opérations sur ces ensembles. Le résultat est souvent une sortie également exprimée de manière floue.

La figure suivante montre le principe d'utilisation d'un contrôleur flou.




FIGURE 2.1 – Contrôleur Flou

1. **Fuzzyfication** : passage du monde réel (une tension, un nombre, ...) à la représentation floue.
2. **Inférence des règles** : déroulement de toutes les règles de description du processus.
3. **Défuzzyfication** : passage de la représentation floue à la représentation réelle.



## 2.2 Problème

Dans cette section, nous aborderons un problème spécifique et tenterons de le résoudre en utilisant un contrôleur flou afin de mieux appréhender son fonctionnement.

### 2.2.1 Enoncé

Les fonctions d'appartenance correspondantes aux paramètres d'entrée et de sortie sont définies par :

Negative Grande (NG)	(-100, -30, -10)
Negative Petite (PN)	(-30, -10, 0)
Envers Zero (EZ)	(-10, 0, 20)
Positive Petite (PP)	(0, 20, 50)
Positive Grande (PG)	(20, 50, 120)

TABLE 2.1 – Paramètre d'entrée puissance réactive mesurée (PM)

V min admissible (Vmiad)	(-13, -10, -8, -10)
V min desiree (Vmid)	(-8, -7, -3, -1)
Envers Zero (EZ)	(-3, -1, 2, 3)
V max desiree (Vmxd)	(2, 3, 5, 6)
V max admissible (Vmxad)	(5, 6, 12, 15)

TABLE 2.2 – Parametre d'entree Niveau de tension (NT)

V min admissible (Vmiad)	(-110, -50, -30)
V min desiree (Vmid)	(-50, -30, -10)
Envers Zero (EZ)	(-30, -10, 10)
V max desiree (Vmxd)	(-10, 10, 60)
V max admissible (Vmxad)	(10, 60, 90)

TABLE 2.3 – Parametre de sortie Puissance Reactive adaptee (PA)

NT \ PM	PG	PP	EZ	NP	NG
Vmiad	PG	PG	PP	PG	PG
Vmin	PG	PP	EZ	PP	PG
EZ	PP	EZ	EZ	EZ	PP
Vmxd	NG	NP	EZ	NP	NG
Vmxad	NG	NG	NP	NG	NG

TABLE 2.4 – Les Règles d’inférence

Simuler le fonctionnement du contrôleur flou en explicitant les différentes étapes avec les paramètres suivants : PM = -25, NT = -2.5

## 2.3 Résolution

Nous avons choisit l’outil fuzzy **fuzzylogic** de **Python** qui est particulièrement utile dans les situations où les règles du système ne peuvent pas être formulées de manière précise ou lorsque l’incertitude est présente. Elle offre une approche plus naturelle et humaine pour modéliser des systèmes complexes où la frontière entre les catégories n’est pas clairement définie.

### 2.3.1 Initialisation des E/S

Première étape, la création des ensembles flous. Dans notre cas, il y a deux variables d’entrée correspondant à :

1. Puissance reactive mesuree (PM))
2. Niveau de tension (NT)

Et un ensemble de sortie : Puissance Reactive adaptee (PA).

```

# Premier controleur d'entrée
PM = Domain('Puissance Reactive mesure', -100, 120)

# Deuxieme controleur d'entrée
NT = Domain('Niveau de Tension', -13, 15)

# Troisième controleur d'entrée
PA = Domain('Puissance Reactive adaptee', -110, 90)

```

FIGURE 2.2 – Entree/Sortie

## 2.3.2 Fuzification

```
# Paramètres d'entrée PM
PM.NG = trapezoid(-100, -30, -30, -10)
PM.NP = trapezoid(-30, -10, -10, 0)
PM.EZ = trapezoid(-10, 0, 0, 20)
PM.PP = trapezoid(0, 20, 20, 50)
PM.PG = trapezoid(20, 50, 50, 120)
PM.NG.plot()
PM.NP.plot()
PM.EZ.plot()
PM.PP.plot()
PM.PG.plot()
```

FIGURE 2.3 – initialisation de PM




FIGURE 2.4 – initialisation de PM

```
# Paramètres d'entrée NT
NT.Vmiad = trapezoid(-13, -10, -8, -7)
NT.Vmid = trapezoid(-8, -7, -3, -1)
NT.EZ = trapezoid(-3, -1, 2, 3)
NT.Vmxd = trapezoid(2, 3, 5, 6)
NT.Vmxad = trapezoid(5, 6, 12, 15)
NT.Vmiad.plot()
NT.Vmid.plot()
NT.EZ.plot()
NT.Vmxd.plot()
NT.Vmxad.plot()
```

FIGURE 2.5 – initialisation de NT




FIGURE 2.6 – initialisation de NT

```

# Paramètres de sortie PA
PA.NG = trapezoid(-110, -50, -50, -30)
PA.NP = trapezoid(-50, -30, -30, -10)
PA.EZ = trapezoid(-30, -10, -10, 10)
PA.PP = trapezoid(-10, 10, 10, 60)
PA.PG = trapezoid(10, 60, 60, 90)
PA.NG.plot()
PA.NP.plot()
PA.EZ.plot()
PA.PP.plot()
PA.PG.plot()

```

FIGURE 2.7 – initialisation de PA




FIGURE 2.8 – initialisation de PA

### 2.3.3 Les Regles

```

1 rules = Rule({
2     (NT.Vmiad, PM.PG): PA.PG, # R1
3     (NT.Vmiad, PM.PP): PA.PG, # R2
4     (NT.Vmiad, PM.EZ): PA.PP, # R3
5     (NT.Vmiad, PM.NP): PA.PG, # R4
6     (NT.Vmiad, PM.NG): PA.PG, # R5
7     (NT.Vmid, PM.PG): PA.PG, # R6
8     (NT.Vmid, PM.PP): PA.PP, # R7
9     (NT.Vmid, PM.EZ): PA.EZ, # R8
10    (NT.Vmid, PM.NP): PA.PP, # R9
11    (NT.Vmid, PM.NG): PA.PG, # R10
12    (NT.EZ, PM.PG): PA.PP, # R11
13    (NT.EZ, PM.PP): PA.EZ, # R12
14    (NT.EZ, PM.EZ): PA.EZ, # R13
15    (NT.EZ, PM.NP): PA.EZ, # R14
16    (NT.EZ, PM.NG): PA.PP, # R15
17    (NT.Vmxd, PM.PG): PA.NG, # R16
18    (NT.Vmxd, PM.PP): PA.NP, # R17
19    (NT.Vmxd, PM.EZ): PA.EZ, # R18
20    (NT.Vmxd, PM.NP): PA.NP, # R19
21    (NT.Vmxd, PM.NG): PA.NG, # R20
22    (NT.Vmxad, PM.PG): PA.NG, # R21
23    (NT.Vmxad, PM.PP): PA.NG, # R22
24    (NT.Vmxad, PM.EZ): PA.NP, # R23
25    (NT.Vmxad, PM.NP): PA.NG, # R24

```

```

26 (NT.Vmxad, PM.NG): PA.NG # R25
27 })

```

## 2.3.4 Fonctionnement

```

1 pm_output = list(PM(-25).values())
2 pm_output = [float(x) for x in pm_output]
3
4 nt_output = list(NT(-2.5).values())
5 nt_output = [float(x) for x in nt_output]
6
7 pa_ng = max(
8     min(pm_output[3], nt_output[3]),
9     min(pm_output[4], nt_output[3]),
10    min(pm_output[0], nt_output[4]),
11    min(pm_output[1], nt_output[4]),
12    min(pm_output[3], nt_output[4]),
13    min(pm_output[4], nt_output[4])
14 )
15 pa_np = max(
16     min(pm_output[1], nt_output[3]),
17     min(pm_output[3], nt_output[3]),
18     min(pm_output[2], nt_output[4])
19 )
20 pa_ez = max(
21     min(pm_output[2], nt_output[1]),
22     min(pm_output[1], nt_output[2]),
23     min(pm_output[2], nt_output[2]),
24     min(pm_output[3], nt_output[2]),
25     min(pm_output[2], nt_output[3])
26 )
27 pa_pp = max(
28     min(pm_output[2], nt_output[0]),
29     min(pm_output[2], nt_output[1]),
30     min(pm_output[2], nt_output[0]),
31     min(pm_output[3], nt_output[2]),
32     min(pm_output[0], nt_output[2])
33 )
34 pa_pg = max(
35     min(pm_output[0], nt_output[0]),

```

```

36         min(pm_output[1], nt_output[0]),
37         min(pm_output[3], nt_output[0]),
38         min(pm_output[4], nt_output[0]),
39         min(pm_output[0], nt_output[1]),
40         min(pm_output[4], nt_output[1])
41     )
42 all_values = [pa_ng, pa_np, pa_ez, pa_pp, pa_pg]
43
44 print(f"Puissance reactive adapte Vegative Grande {pa_ng}\nNegative
      Petite {pa_np}\nEnvers Zero {pa_ez}\nPositive Petite {pa_pp}\nPositive
      Grande {pa_pg}")

```

## 2.3.5 Defuzzification

```

fig, axis = plt.subplots(figsize=(7, 5))

x_PA = PA.range

PA_0 = np.zeros_like(x_PA)
parametres_PA = [PA.NG, PA.NP, PA.EZ, PA.PP, PA.PG]
j=0
colors = ['y', 'b', 'g', 'm', 'r']
for each in parametres_PA:
    axis.plot(x_PA, each.array(), colors[j], linewidth=1)
    axis.fill_between(x_PA, PA_0, [min(all_values[j], x) for x in each.array()], facecolor=colors[j], alpha=0.7)
    j+=1

```

FIGURE 2.9 – Defuzzification




FIGURE 2.10 – Resultat finale

```

▶ values = {PM: -25, NT: -2.5}
  centre_de_gravite = rules(values)
  print(f"Centre de gravite obtenu avec les valeurs PM = -25, NT = -2.5 est egale a : {centre_de_gravite}")

```

Centre de gravite obtenu avec les valeurs PM = -25, NT = -2.5 est egale a : 30.96185737976782

FIGURE 2.11 – Centre de Gravite

## 2.4 Conclusion

Dans cette section, nous nous sommes initiés aux contrôleurs flous. En mettant en pratique nos connaissances à travers une application concrète, nous avons amélioré notre compréhension de leur mécanisme, en particulier la manière de les concevoir et de les mettre en œuvre.

# TP3 :Réseaux causaux Bayésiens

## 3.1 Introduction :

Les réseaux causaux bayésiens sont des outils puissants utilisés dans le domaine de la modélisation probabiliste pour représenter et analyser les relations de cause à effet entre différentes variables. Ces réseaux combinent les concepts de la théorie des probabilités bayésiennes avec la représentation graphique des relations causales.

## 3.2 Outil choisie :

PGMPY : Une bibliothèque Python pour les réseaux Bayésiens, Dans ce qui suit, nous allons implémenter un exemple de réseau bayésien avec une structure graphique de poly-arbre et aussi de multi-connected en suivant les étapes données dans l'énoncé du TP.

## 3.3 ÉTAPE 1 : Installation de PGMPY

```
pip install pgmpy
Collecting pgmpy
  Downloading pgmpy-0.1.24-py3-none-any.whl (2.0 MB)
    2.0/2.0 MB 21.4 MB/s eta 0:00:00
Requirement already satisfied: networkx in /usr/local/lib/python3.10/dist-packages (from pgmpy) (3.2.1)
Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from pgmpy) (1.23.5)
Requirement already satisfied: scipy in /usr/local/lib/python3.10/dist-packages (from pgmpy) (1.11.4)
Requirement already satisfied: scikit-learn in /usr/local/lib/python3.10/dist-packages (from pgmpy) (1.2.2)
Requirement already satisfied: pandas in /usr/local/lib/python3.10/dist-packages (from pgmpy) (1.5.3)
Requirement already satisfied: pyparsing in /usr/local/lib/python3.10/dist-packages (from pgmpy) (3.1.1)
Requirement already satisfied: torch in /usr/local/lib/python3.10/dist-packages (from pgmpy) (2.1.0+cu118)
Requirement already satisfied: statsmodels in /usr/local/lib/python3.10/dist-packages (from pgmpy) (0.14.0)
Requirement already satisfied: tqdm in /usr/local/lib/python3.10/dist-packages (from pgmpy) (4.66.1)
Requirement already satisfied: joblib in /usr/local/lib/python3.10/dist-packages (from pgmpy) (1.3.2)
Requirement already satisfied: opt-einsum in /usr/local/lib/python3.10/dist-packages (from pgmpy) (3.3.0)
Requirement already satisfied: python-dateutil>=2.8.1 in /usr/local/lib/python3.10/dist-packages (from pandas->pgmpy) (2.8.2)
Requirement already satisfied: pytz>=2020.1 in /usr/local/lib/python3.10/dist-packages (from pandas->pgmpy) (2023.3.post1)
Requirement already satisfied: threadpoolctl>=2.0.0 in /usr/local/lib/python3.10/dist-packages (from scikit-learn->pgmpy) (3.2.0)
Requirement already satisfied: patsy>=0.5.2 in /usr/local/lib/python3.10/dist-packages (from statsmodels->pgmpy) (0.5.3)
Requirement already satisfied: packaging>=21.3 in /usr/local/lib/python3.10/dist-packages (from statsmodels->pgmpy) (23.2)
Requirement already satisfied: filelock in /usr/local/lib/python3.10/dist-packages (from torch->pgmpy) (3.13.1)
Requirement already satisfied: typing-extensions in /usr/local/lib/python3.10/dist-packages (from torch->pgmpy) (4.5.0)
Requirement already satisfied: sympy in /usr/local/lib/python3.10/dist-packages (from torch->pgmpy) (1.12)
Requirement already satisfied: jinja2 in /usr/local/lib/python3.10/dist-packages (from torch->pgmpy) (3.1.2)
Requirement already satisfied: fsspec in /usr/local/lib/python3.10/dist-packages (from torch->pgmpy) (2023.6.0)
Requirement already satisfied: triton==2.1.0 in /usr/local/lib/python3.10/dist-packages (from torch->pgmpy) (2.1.0)
Requirement already satisfied: six in /usr/local/lib/python3.10/dist-packages (from patsy>=0.5.2->statsmodels->pgmpy) (1.16.0)
Requirement already satisfied: MarkupSafe>=2.0 in /usr/local/lib/python3.10/dist-packages (from jinja2->torch->pgmpy) (2.1.3)
Requirement already satisfied: mpmath>=0.19 in /usr/local/lib/python3.10/dist-packages (from sympy->torch->pgmpy) (1.3.0)
Installing collected packages: pgmpy
Successfully installed pgmpy-0.1.24
```

FIGURE 3.1 – Installation de PGMPY



### 3.4 ETAPE2 : Poly-Arbre

Nous avons implémenter un réseau bayésien pour modéliser des notions du domaine changement de climat.

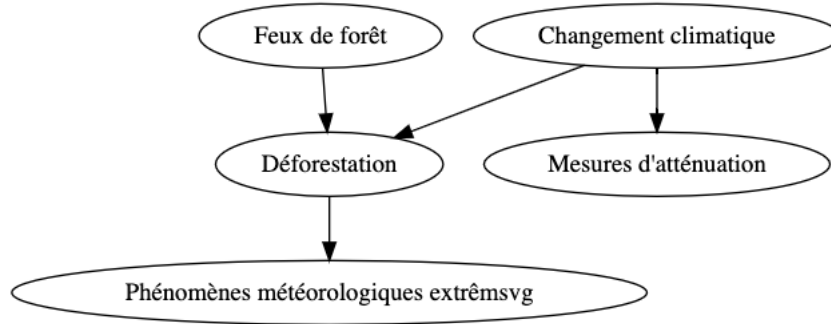


FIGURE 3.2 – Réseau bayésien des notions de changement de climat

Ce réseau graphique montre la causalité entre les concepts de changement de climat. Dans ce qui suit, nous allons présenter la distribution des probabilités conditionnelles de chaque concept :

#### Modélisation

- Deforestation : D
- Feux de foret : F
- Phénomènes météorologiques extrêmes : P
- Mesures d'atténuation : M
- Changement Climatique : C

#### La représentation numérique des noeuds :

on est dans le domaine probabiliste donc on peut faire la représentation numérique respectons :

- Si  $(U_A) = \emptyset$  (A est un nœud racine) alors, il s'agit de spécifier les probabilités a priori relatives aux différentes instances de la variable A, tout en respectant la condition de normalisation qui stipule que :

$$\sum_a P(a) = 1$$

- Si  $(U_A) \neq \emptyset$  alors il faudrait spécifier les probabilités conditionnelles des différentes instances  $a$  de A dans le contexte des différentes instances de ses parents  $u_A$  telles que :

$$\sum_a P(a | u_A) = 1$$

FIGURE 3.3 – Distribution conditionnels

<b>F</b>	<b>P(F)</b>
Faux	0.6
Vrai	0.4
<b>C</b>	<b>P(C)</b>
Faux	0.7
Vrai	0.3

<b>D</b>	<b>P</b>	<b>P(P D)</b>
Faux	Faux	0.9
Faux	Vrai	0.1
Vrai	Faux	0.95
Vrai	Vrai	0.05

<b>F</b>	<b>C</b>	<b>D</b>	<b>P(D F, C)</b>
Faux	Faux	Faux	0.7
Faux	Faux	Vrai	0.3
Faux	Vrai	Faux	0.8
Faux	Vrai	Vrai	0.2
Vrai	Faux	Faux	0.95
Vrai	Faux	Vrai	0.05
Vrai	Vrai	Faux	0.8
Vrai	Vrai	Vrai	0.2

<b>C</b>	<b>M</b>	<b>P(M C)</b>
Faux	Faux	0.8
Faux	Vrai	0.2
Vrai	Faux	0.9
Vrai	Vrai	0.1

### 3.4.1 Modelisation avec PGMPY

```
from pgmpy.factors.discrete import TabularCPD
from pgmpy.models import BayesianNetwork
# Etablissement de la structure
climate_model = BayesianNetwork([
    ('F', 'D'),
    ('C', 'D'),
    ('D', 'P'),
    ('C', 'M'),
])
# Définition des relations
fire_cpd = TabularCPD(
    variable='F',
    variable_card=2,
    values=[[.6], [.4]]
)

climate_cpd = TabularCPD(
    variable='C',
    variable_card=2,
    values=[[.7], [.3]]
)

mitigation_cpd = TabularCPD(
    variable='M',
    variable_card=2,
    values=[[.8, .9],
            [.2, .1]],
    evidence=['C'],
    evidence_card=[2]
)

deforestation_cpd = TabularCPD(
    variable='D',
    variable_card=2,
    values=[[.7, .8, .95, .8], [.3, .2, .05, .2]],
    evidence=['F', 'C'],
    evidence_card=[2, 2]
```

```

)

extreme_weather_cpd = TabularCPD(
    variable='P',
    variable_card=2,
    values=[[.9, .95], [.1, .05]],
    evidence=['D'],
    evidence_card=[2]
)

# Ajout des relations à notre modèle
climate_model.add_cpds(deforestation_cpd, fire_cpd, climate_cpd, mitigation_cpd,
    ↪ extreme_weather_cpd)

# Re-vérification de la structure de notre modèle
climate_model.get_cpds()

[<TabularCPD representing P(D:2 | F:2, C:2) at 0x7a4d26c08f10>,
 <TabularCPD representing P(F:2) at 0x7a4de0d46e60>,
 <TabularCPD representing P(C:2) at 0x7a4de0d460b0>,
 <TabularCPD representing P(M:2 | C:2) at 0x7a4de0d448b0>,
 <TabularCPD representing P(P:2 | D:2) at 0x7a4de0d45ae0>]

```

```

[4]:
from pgmpy.inference import VariableElimination
# Calcul des probabilités existantes pour vérifier que tout est correct
prob_deforestation = VariableElimination(climate_model).query(variables=['D'])
print(prob_deforestation)

```

```

+-----+-----+
| D      | phi(D) |
+=====+=====+
| D(0)   | 0.8000 |
+-----+-----+
| D(1)   | 0.2000 |
+-----+-----+

```

```

[5]:

```

```
# Faire un autre calcul de probabilité
prob_extreme_weather = VariableElimination(climate_model).query(variables=['P'])
print(prob_extreme_weather)
```

```
+-----+-----+
| P      | phi(P) |
+=====+=====+
| P(0)   | 0.9100 |
+-----+-----+
| P(1)   | 0.0900 |
+-----+-----+
```

```
[6]: # Probabilité d'avoir le changement climatique si on a la déforestation
proba_climate_deforestation = VariableElimination(climate_model).
    ↪query(variables=['C'], evidence={'D': 1})
print(proba_climate_deforestation)
```

```
+-----+-----+
| C      | phi(C) |
+=====+=====+
| C(0)   | 0.7000 |
+-----+-----+
| C(1)   | 0.3000 |
+-----+-----+
```

```
[7]: # Probabilité d'avoir des mesures d'atténuation si on a le changement climatique
proba_mitigation_climate = VariableElimination(climate_model).
    ↪query(variables=['M'], evidence={'C': 1})
print(proba_mitigation_climate)
```

```
+-----+-----+
| M      | phi(M) |
+=====+=====+
| M(0)   | 0.9000 |
+-----+-----+
| M(1)   | 0.1000 |
+-----+-----+
```

### 3.5 ETAPE3 : Multi-Arbre

Nous avons conçu un réseau bayésien pour modéliser la causalité entre les concepts de changement de climat.

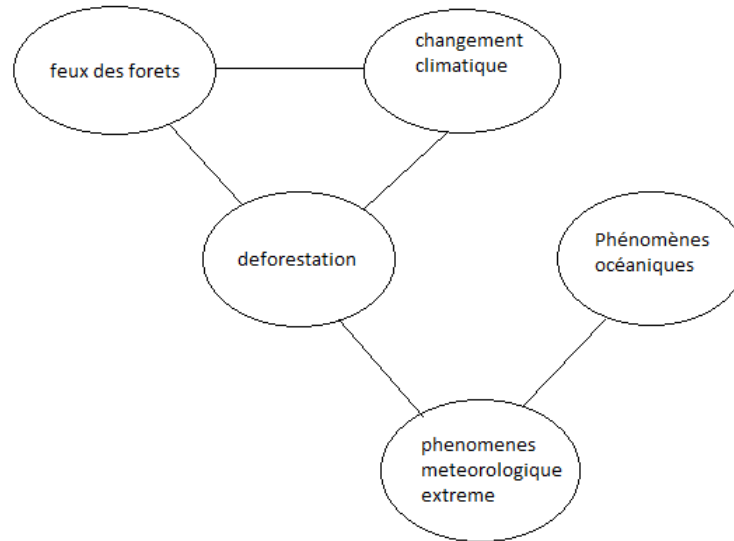


FIGURE 3.4 – Réseau bayésien des notions de changement de climat

#### **La representation numerique des noeud :**

on est dans le domaine probabiliste donc on peut faire la representation numerique respectons :

$F$	$C$	$P(F)$
Faux	Faux	0.6
Faux	Vrai	0.4
Vrai	Faux	0.3
Vrai	Vrai	0.7

(a)

$C$	$P(C)$
Faux	0.75
Vrai	0.25

(b)

$C$	$F$	$D$	$P(D C, F)$
Faux	Faux	Faux	0.99
Faux	Faux	Vrai	0.01
Faux	Vrai	Faux	0.8
Faux	Vrai	Vrai	0.2
Vrai	Faux	Faux	0.7
Vrai	Faux	Vrai	0.3
Vrai	Vrai	Faux	0.4
Vrai	Vrai	Vrai	0.6

(c)

$O$	$P(O)$
Faux	0.6
Vrai	0.4

(d)

$P$	$O$	$P$	$P(P D, O)$
Faux	Faux	Faux	0.9
Faux	Faux	Vrai	0.1
Faux	Vrai	Faux	0.4
Faux	Vrai	Vrai	0.6
Vrai	Faux	Faux	0.2
Vrai	Faux	Vrai	0.8
Vrai	Vrai	Faux	0.3
Vrai	Vrai	Vrai	0.7

(e)

FIGURE 3.5 – Description des tableaux

### 3.5.1 Modelisation avec PGMPY

```

1 from pgmpy.factors.discrete import TabularCPD
2 from pgmpy.models import BayesianNetwork
3
4 # Establishing the structure
5 climate_model = BayesianNetwork([
6     ('C', 'F'),
7     ('C', 'D'),
8     ('F', 'D'),
9     ('D', 'P'),
10    ('O', 'P'),
11 ])

```

```

12
13 # Defining the relationships
14 changement_climate_cpd = TabularCPD(
15     variable='C',
16     variable_card=2,
17     values=[[.75], [.25]]
18 )
19
20 feu_cpd = TabularCPD(
21     variable='F',
22     variable_card=2,
23     values=[[.6, .3],
24             [.4, .7]],
25     evidence=['C'],
26     evidence_card=[2]
27 )
28
29 defostration_cpd = TabularCPD(
30     variable='D',
31     variable_card=2,
32     values=[
33         [.99, .8, .7, .4], [.01, .2, .3, .6]],
34     evidence=['C', 'F'],
35     evidence_card=[2, 2]
36 )
37
38 ocean_cpd = TabularCPD(
39     variable='O',
40     variable_card=2,
41     values=[[.6], [.4]]
42 )
43
44 phenomenes_cpd = TabularCPD(
45     variable='P',
46     variable_card=2,
47     values=[[.9, .4, .2, .3], [.1, .6, .8, .7]],
48     evidence=['O', 'D'],
49     evidence_card=[2, 2]
50 )
51

```



```

52 # Adding the relationships to our model
53 climate_model.add_cpds(changement_climate_cpd,
54                        feu_cpd, defostration_cpd, ocean_cpd,
55                        phenomenes_cpd)
56
57 # Checking the structure of our model
58 climate_model.get_cpds()

```

```

[11] from pgmpy.inference import VariableElimination
climate_infer = VariableElimination(climate_model)
#calcul des proba existante pour vérifier que tout est correct
prob_changement = climate_infer.query(variables=['C'])
print(prob_changement)

```

C	phi(C)
C(0)	0.7500
C(1)	0.2500



```

#probabilité d'avoir un phenomene meteorologique quand il ya une defostration
proba_phenomene_def = climate_infer.query(variables=['P'], evidence= {'D':1})
print(proba_phenomene_def)

```



P	phi(P)
P(0)	0.3600
P(1)	0.6400

FIGURE 3.6 – Performance de notre modele multi-connected

### 3.6 ETAPE4 : Générez un graphe à connexions multiples avec un Grand Nombre de Variables et de Parents

```

1 import networkx as nx
2 import random
3

```

```

4 def generate_random_bayesian_network(num_nodes, max_parents_per_node):
5     # Cr ation d'un graphe dirige
6     G = nx.DiGraph()
7
8     # Ajout des noueds au graphe
9     for i in range(num_nodes):
10         G.add_node(f'X{i}')
11
12     # Ajout des arcs entre les noeuds
13     for i in range(num_nodes):
14         num_parents = random.randint(0, min(i, max_parents_per_node))
15         parents = random.sample(range(i), num_parents)
16         for parent in parents:
17             G.add_edge(f'X{parent}', f'X{i}')
18
19     # Attribution de probabilites aleatoires aux CPDs
20     for node in G.nodes():
21         num_states = random.randint(2, 5) # Nombre al atoire d' tats
22         pour chaque variable
23         states = [f'State{i}' for i in range(num_states)]
24         cpd_values = [random.random() for _ in range(num_states)]
25         cpd_values = [val / sum(cpd_values) for val in cpd_values] #
26         Normalisation des probabilit s
27         G.nodes[node]['states'] = states
28         G.nodes[node]['probabilities'] = cpd_values
29
30     return G
31
32 # Param tres
33 num_nodes = 10 # Nombre total de variables
34 max_parents_per_node = 3 # Nombre maximal de parents par variable
35
36 # G n ration du r seau bay sien
37 random_bayesian_network = generate_random_bayesian_network(num_nodes,
38                                                             max_parents_per_node)
39
40 # Affichage du graphe
41 pos = nx.spring_layout(random_bayesian_network)
42 nx.draw(random_bayesian_network, pos, with_labels=True, font_weight='bold
43         ', node_size=700, node_color='skyblue', font_size=8)

```

```
40 nx.draw_networkx_edge_labels(random_bayesian_network, pos, edge_labels={(  
    i, j): '' for i, j in random_bayesian_network.edges()})
```

## 3.7 Conclusion

En conclusion, l'étude approfondie des réseaux bayésiens polyarbres et multiconnectés a permis de modéliser avec précision les dépendances complexes entre variables. L'analyse des distributions conditionnelles des probabilités des nœuds a enrichi notre compréhension des relations probabilistes.

# TP4 : Logique possibiliste qualitative

## 4.1 Introduction

La logique possibiliste qualitative vise à traiter l'incertitude et l'imprécision dans le raisonnement logique en utilisant des degrés de certitude plutôt que des valeurs binaires (vrai/faux). Dans ce contexte, le problème de déduction se pose comme suit :

1. **Objectif de la déduction possibiliste** : Calculer le degré d'inconsistance ( $\text{Incons}$ ) d'un ensemble de connaissances  $\Sigma$  étendu par la négation d'une proposition  $\phi$  (notée ici comme  $\neg\phi$ ).
2. **Mesure d'inconsistance** : La mesure d'inconsistance est définie comme  $\text{Incons}(\Sigma \cup \{\neg\phi\}) = \text{val}(\phi, \Sigma)$ , où  $\text{val}(\phi, \Sigma)$  représente le degré de certitude que la proposition  $\phi$  est vraie dans le contexte de connaissances  $\Sigma$ .
3. **Utilisation du principe de réfutation** : La déduction se base sur le principe de réfutation. Prouver que  $\Sigma$  infère  $(\phi, \alpha)$  est équivalent à prouver que l'ensemble étendu  $\Sigma \cup \{\neg\phi\}$  est inconsistant, c'est-à-dire qu'il conduit à une contradiction.
4. **Test d'inconsistance** : Le test d'inconsistance est matérialisé par l'utilisation de prouveurs SAT (*satisfiability*) qui sont des outils algorithmiques utilisés pour déterminer la satisfaisabilité d'une formule logique. Si l'ensemble étendu  $\Sigma \cup \{\neg\phi\}$  est satisfaisable, alors  $\Sigma \wedge \neg\phi$  est consistant, et le processus de dichotomie ajuste la borne supérieure ( $u$ ) en conséquence. Sinon, si  $\Sigma \wedge \neg\phi$  est inconsistant, le processus ajuste la borne inférieure ( $l$ ).
5. **Principe de dichotomie** : L'algorithme d'inférence utilise le principe de dichotomie pour réduire l'intervalle  $[l, u]$  jusqu'à ce que la borne inférieure  $l$  soit égale à la borne supérieure  $u$ . À chaque étape, l'algorithme divise l'intervalle en deux, teste l'inconsistance de  $\Sigma^* \wedge \neg\phi$ , et ajuste les bornes en conséquence.

**En résumé**, l'algorithme cherche à trouver le degré de certitude ( $\alpha$ ) pour lequel l'ensemble étendu  $\Sigma \cup \{\neg\phi\}$  devient inconsistant, en utilisant une approche de recherche dichotomique pour réduire l'intervalle des valeurs possibles. L'utilisation de prouveurs SAT facilite le test d'inconsistance dans ce contexte de logique possibiliste qualitative.

Voici le pseudo code de l'algorithme :

**Algorithme 1** : Algorithme de Dichotomie pour l'Inférence en Logique Possibiliste

```
1 Input :  $n, \Sigma, \phi$ 
2 Output :  $l, u$ 
3 Initialization :  $l := 0, u := n$ 
4 tant que  $l < u$  faire
5    $r := \lfloor \frac{l+u}{2} \rfloor$ 
6   si  $\Sigma^* \wedge \neg \phi$  consistent alors
7      $u := r - 1$ 
8   fin si
9   sinon
10     $l := r$   $\{\text{Val}(\phi, \Sigma) = \alpha_r\}$ 
11  fin si
12 fin tq
```

## 4.2 La création de la base de connaissances pondérée

```
1 import random
2 import os
3
4 class BaseConnaissance:
5     number_of_clause = 0
6     number_of_variable = 0
7     evidence_length = 0
8     var_list = []
9     max_clause_length = 0
10
11     def __init__(self, nb_clause, nb_variable, length, max_number):
12         self.number_of_clause = nb_clause
13         self.number_of_variable = nb_variable
14         self.evidence_length = length
15         self.max_clause_length = max_number
16         for i in range(self.number_of_variable):
17             self.var_list.append(i + 1)
18             self.var_list.append(-(i + 1))
19
20     def get_evidence(self):
21         return random.sample(self.var_list, self.evidence_length)
22
23     def get_sigma(self):
24         with open("temp.txt", "w") as sigma_file:
```

```

25         for i in range(self.number_of_clause):
26             ran = random.randrange(1, self.max_clause_length + 1, 1)
27             temp_list = random.sample(self.var_list, ran)
28             weight = random.random()
29             weight = float(int(weight * 100)) / 100
30             chaine = "" + str(weight) + " "
31             for j in range(len(temp_list)):
32                 chaine = chaine + str(temp_list[j]) + " "
33             sigma_file.write(chaine + "\n")
34             temp_list = []

```

## 4.3 L'implémentation de l'algorithme en utilisant un prouver SAT

```

1 class Sigma:
2     lower = 0
3     upper = 0
4     weights = []
5     formulas = []
6     strates_weights = []
7
8     def __init__(self, path_file):
9         with open(path_file) as file:
10             for line in file:
11                 information = line.split()
12                 self.weights.append(float(information[0]))
13                 self.formulas.append([int(information[i]) for i in range
14 (1, len(information))])
15                 self.length = len(self.weights)
16
17     def get_length(self):
18         return self.length
19
20     def get_weights(self):
21         return self.weights
22
23     def get_formulas(self):
24         return self.formulas

```

```

24
25     def sort_weights(self):
26         sorted_data = sorted(zip(self.weights, self.formulas), reverse=
True)
27         self.weights, self.formulas = zip(*sorted_data)
28
29     def compute_strates(self):
30         self.upper = len(set(self.weights))
31         self.strates_weights = sorted(set(self.weights))
32
33     def get_strates_number(self):
34         return self.upper
35
36     def get_strates_weights(self):
37         return self.strates_weights
38
39     def get_preprocessed_formulas(self, sub_formulas):
40         dict_cor = {}
41         returned_formulas = []
42         cpt = 1
43
44         for form in sub_formulas:
45             temp_form = []
46             for pred in form:
47                 if pred not in dict_cor:
48                     dict_cor[pred] = cpt
49                     dict_cor[-pred] = -cpt
50                     cpt += 1
51                 temp_form.append(dict_cor[pred])
52             returned_formulas.append(temp_form)
53
54         return returned_formulas

```

4.4 L'algorithme calcule la variable d'intérêt  $\Pi$ , qui correspond à  $val(\phi, \Sigma)$

```

1 import pycosat
2 from prettytable import PrettyTable

```

```

3
4 choice = 1
5 if choice == 1:
6     base_de_connaissance = Sigma("/content/drive/MyDrive/data/BD.wcnf")
7     evidence = [3, 4, -7]
8 else:
9     nb_clause = 8
10    nb_variable = 5
11    length = 3
12    max_number = 4
13    gen = BaseConnaissance(nb_clause, nb_variable, length, max_number)
14    gen.get_sigma()
15    base_de_connaissance = Sigma("temp.txt")
16    evidence = gen.get_evidence()
17
18 base_de_connaissance.sort_weights()
19 base_de_connaissance.compute_strates()
20 iteration = 1
21
22 while base_de_connaissance.lower < base_de_connaissance.upper:
23     r = int((base_de_connaissance.lower + base_de_connaissance.upper + 1)
24             / 2)
25
26     liste = base_de_connaissance.get_weights()
27     value_of_r = -1
28     for i in range(len(liste)):
29         if base_de_connaissance.get_strates_weights()[r - 1] > liste[i]:
30             value_of_r = i
31             break
32     if value_of_r == -1:
33         value_of_r = len(liste) - 1
34
35     for j in range(len(liste)):
36         if base_de_connaissance.get_strates_weights()[
37             base_de_connaissance.upper - 1] == liste[j]:
38             valueU = j
39             break
40
41     cnf = base_de_connaissance.formulas[valueU:value_of_r]

```



```

41     for i in range(len(evidence)):
42         liste = []
43         liste.append(-1 * evidence[i])
44         cnf = list(base_de_connaissance.get_preprocessed_formulas(cnf))
45
46     cnf = base_de_connaissance.get_preprocessed_formulas(cnf)
47
48     result = pycosat.solve(cnf)
49     if type(result) == type([]):
50         base_de_connaissance.upper = r - 1
51     else:
52         base_de_connaissance.lower = r
53     iteration = iteration + 1
54
55 Val = base_de_connaissance.get_strates_weights()[r - 1]
56
57 with open("/content/drive/MyDrive/data/BD.wcnf") as f:
58     content = f.read().splitlines()
59     table = PrettyTable()
60     table.field_names = ["Poids", "PropositionP1", "PropositionP2"]
61     for line in content:
62         row_values = line.split()
63         while len(row_values) < len(table.field_names):
64             row_values.append('')
65         table.add_row(row_values)
66
67     print(table)
68     print("**L evidence de : ", evidence)
69     print("**Le resultat : Val(" + str(evidence) + ", Sigma) = " + str(Val))

```

Le résultat est le suivant :

+-----+-----+-----+			
Poids		PropositionP1	PropositionP2
+-----+-----+-----+			
0.6		1	2
0.55		2	3
0.5		-2	
0.4		4	
0.3		5	
0.2		6	
+-----+-----+-----+			
**L evidence de : [3, 4, -7]			
**Le resultat : Val([3, 4, -7], Sigma) = 0.2			

FIGURE 4.1 – Resultat d’inerence

## 4.5 Conclusion

Le but de ce TP en logique possibiliste qualitative est de traiter le problème de déduction dans ce contexte. Plus précisément, le TP se focalise sur l’algorithme d’inférence qui utilise le principe de dichotomie pour calculer le degré d’inconsistance d’une base de connaissances pondérées  $\Sigma$ .

# TP 5 : Théorie des possibilités : Inférence logique et propagation graphique

## 5.1 Introduction

Dans ce dernier TP, nous allons exécuter l'inférence et la propagation graphique en théorie des possibilités en utilisant l'outil PNT. pour exécuter ce dernier, nous allons utiliser Cygwin un émulateur Unix pour Windows pour exécuter les deux programmes `passage.exe` et `inference.exe`. Après avoir fait fonctionner l'outil, nous allons tester les différents temps d'exécution de la propagation et l'inférence sur les réseaux possibilités qui correspondent à polyarbre, Graphes faiblement connectés, Graphes moyennement connectés et Graphes fortement connectés.

## 5.2 Utilisation de Cygwin

Le premier programme est lié au graphe possibiliste basé sur le produit et à la base de connaissance possibiliste quantitative correspondante. Lorsque nous exécutons le programme "`inference.exe`" pour initier le processus d'inférence, cela implique le calcul du degré de possibilité de l'instance de la variable d'intérêt, ainsi que la mesure du temps d'inférence. Pour exécuter ces deux programmes, "`passage.exe`" et "`inference.exe`", nous utiliserons Cygwin.

### 5.2.1 ÉTAPE 1 : Utilisation d'un algorithme de propagation pour les réseaux possibilistes basés sur le produit

Avant d'exécuter les deux programmes, nous devons d'abord exécuter les scripts MATLAB '`prop1evid`' ou '`prop2evid`' pour générer le graphe de possibilité.

## 5.2.2 ÉTAPE 2 : Exécution des fichiers

```
VLADE@DESKTOP-HUHORPD /home
$ cd licence

VLADE@DESKTOP-HUHORPD /home/licence
$ ./passage.exe

VLADE@DESKTOP-HUHORPD /home/licence
$ ./inference.exe
236975
VLADE@DESKTOP-HUHORPD /home/licence
$ cat resultats
*****Résultats de la propagation graphique*****
nombre de variables: 38
nombre de parentsmax: 3
l'evidence: -31
variable d'interet: 25
possibilité conditionnelle de l'interet | evidences 0.018316
temps de propagation 0.220853 secondes

*****Résultats de l'inférence logique*****
le nombre de clauses dans les bases est de: 146
la variable d'interet est inférée à partir de la base de pénalités
le coût de pénalité est de 4
avec un degré de possibilité correspondant est égale à :0.018316
la durée de l'inférence est: 236975 millisecondes
VLADE@DESKTOP-HUHORPD /home/licence
$
```

FIGURE 5.1 – Résultats de l'exécution du fichier 1

## 5.2.3 Evaluation

Nous avons effectué des évaluations sur les nombres de nœuds pour chaque scénario (polyarbre, Graphes faiblement connectés, Graphes moyennement connectés et Graphes fortement connectés) pour une évidence puis pour deux évidences.

Nous avons pris 1 parent pour avoir un polyarbre, 3 parents pour avoir un Graphe faiblement connectés, 10 parents pour un Graphe moyennement connectés et enfin 20 parents pour avoir un Graphe fortement connectés. Pour le nombre de nœuds, nous avons testé les valeurs suivantes : [5, 10, 15, 20]. les résultats obtenus pour l'inférence et la propagation pour une évidence puis 2 évidences sont présentées ci-dessous.

nb nodes	nb de parents			
	1	3	10	20
5	76800	79556	86009	70713
10	80881	70009	86301	71781
15	69980	71530	78269	95093
20	68135	91594	85614	83655

TABLE 5.1 – Temps d'exécution de l'inférence en ms pour une évidence

nb nodes	nb de parents			
	1	3	10	20
5	0	0.032381	0.010385	0.012787
10	0	0.033178	0.018347	0.018947
15	0	0.049536	0.036939	0.036784
20	0	0.067523	0.054596	0.105959

TABLE 5.2 – Temps d'exécution de la propagation en secondes pour une évidence

nb nodes	nb de parents			
	1	3	10	20
5	69612	68500	67124	89463
10	70760	70313	83714	77229
15	68381	69963	73974	134646
20	83144	87290	90105	1156560

TABLE 5.3 – Temps d'exécution d'inférence en secondes pour deux évidences

nb nodes	nb de parents			
	1	3	10	20
5	2	2	1	2
10	0	1	1	2
15	0	1	1	2
20	0	1	2	1

TABLE 5.4 – Temps d'exécution de la propagation en secondes pour deux évidences

# Conclusion Generale

Ces travaux pratiques nous ont permis d'explorer les diverses logiques sur lesquelles un système informatique peut fonctionner. Nous avons acquis des compétences en modélisation de problèmes réels, en génération d'inférences, en utilisation de raisonneurs pour évaluer la validité de propositions, en représentation graphique d'informations, et en déduction de faits.